运营复盘

智能体运维半年复盘

给平台、应用与风控团队看的 2025 下半年运行总结。

平台稳定性小组
版本 V1.2 · 2026.04
North Harbor AI

目录

01 执行摘要 03

02 背景与问题定义 04

03 方法与发现 06

04 结论与建议 09

05 附录 11

01 · EXECUTIVE SUMMARY

执行摘要

过去六个月，智能体系统最明显的变化不是模型更强，而是 失败模式更可预测。这意味着我们终于可以把“修 bug”转成“做治理”，把偶发事故转成明确的工程约束。

核心 Takeaways

- 人工接管率从 19% 降到 11%，但跨工具任务仍是主要失效率来源。
- 高峰期成本问题不在模型单价，而在上下文膨胀与重复检索。
- 下一阶段最该投的是任务边界治理，而不是继续堆更多工具。

本文档回答的问题

1) 哪类任务已经进入稳定可交付区间？2) 哪类失败仍然需要人类兜底？3) 下一阶段最该优先投入的平台能力是什么？

02 · BACKGROUND

背景与问题定义

这一章回答一个核心问题：我们到底是在优化一个“模型问题”，还是一个“系统问题”。

当前现状

从 2025 年 10 月到 2026 年 3 月，我们服务了 420 万次生产请求，覆盖客服、内部知识问答、报表生成和多工具执行四类任务。整体成功率提升 9 个百分点，但跨系统任务波动仍大。

核心问题

真正拖慢交付的不是单点模型性能，而是任务链中的责任边界不清，导致模型反复尝试无效步骤、上下文持续膨胀。

> 当一个任务需要四个以上工具协作时，失败最常见的原因不再是模型“不知道答案”，而是它不知道“现在该停下”。

衡量标准

维度	当前水平	目标水平	差距
人工接管率	12%	12%	-3pct
任务成功率	12%	12%	+6pct

03 · METHODOLOGY

方法与发现

方法部分聚焦日志切片、失败归因和成本拆解，目标是把运气成分剥离出去。

研究方法

我们把请求按任务长度、调用工具数、是否需要外部写操作分桶，并跟踪首次响应、最终完成和人工接管三个节点。

```
示例代码块
def analyze(data):
    return transform(data)
```

关键发现

发现 1：标题

在 8k 到 24k token 区间内，完成率提升接近停滞，但成本继续上升。说明更长上下文只在少数复杂任务上有效，普遍策略应改为压缩与检索重排。

发现 2：标题

当可用工具从 6 个增加到 14 个，执行错误只小幅增加，规划错误却翻倍。工具过多让模型更容易“做错第一步”。

> “我们以为更多工具会让系统更聪明，结果只是让它更容易走神。”
>
> - 平台 SRE 值班复盘会，2026.03，日期

04 · CONCLUSIONS

结论与建议

方法部分聚焦日志切片、失败归因和成本拆解，目标是把运气成分剥离出去。

核心结论

1. 结论 1
2. 结论 2
3. 结论 3

下一步建议

建议在 Q3 之前完成任务分类、工具白名单和人工接管面板三项基础设施建设，并把新增场景全部纳入同一套故障分类。

CALL TO ACTION

如果下周一只能做一件事，就先给所有写操作工具补齐“前置确认 + 失败回滚 + 结果摘要”三段式护栏。

05 · APPENDIX

附录

A. 参考资料

- Internal agent operations dataset, North Harbor AI, 2025.10-2026.03
- OpenAI / Anthropic / internal benchmarking notes, compiled 2026.02

B. 术语表

人工接管：用户或人工运营在流程中途接手，替代模型继续执行。

任务边界：一次任务中允许模型自主扩展的范围，包括工具、时长与副作用约束。

C. 致谢

感谢平台工程、应用交付、风控运营三组提供故障日志与访谈材料。